

Universidad del Valle de Guatemala

Facultad de Ingeniería

Hoja de Trabajo 1

CC3104 – Aprendizaje por Refuerzo

Integrantes:

Andy Fuentes — 22944

Diederich Solís — 22952

Diego Linares — 221256

Fecha: 13 de julio de 2026

1 Task 1: Análisis de un sistema mediante Aprendizaje por Refuerzo

Para responder las preguntas se eligió como sistema real un **motor inteligente de prevención de fraude en banca digital**. El sistema analiza cada operación realizada desde la banca móvil o web y decide cómo actuar antes de autorizarla. Este dominio es adecuado para aprendizaje por refuerzo porque cada decisión produce consecuencias inmediatas, como aprobar una compra, y consecuencias posteriores, como una pérdida monetaria, una reclamación o el abandono de una operación legítima.

1.1 Pregunta 1: Estado, acciones, recompensa y observabilidad

Pregunta:

Elija un sistema real de su área de interés. Identifique y justifique para ese sistema: (a) qué representa el estado S_t , (b) qué acciones componen el espacio $\mathcal{A}$, (c) cómo diseñaría la función de recompensa R , y (d) si el entorno es totalmente observable o parcialmente observable, y por qué.

Respuesta:

a) Estado S_t . El estado representa la información disponible en el instante en que se evalúa una transacción. Para que la decisión sea útil, S_t debería incluir:

- monto, moneda, comercio y categoría de la transacción;
- hora, ubicación aproximada y canal utilizado;
- dispositivo, dirección IP y método de autenticación;
- frecuencia y monto acumulado de operaciones recientes;
- diferencia entre la operación actual y el comportamiento histórico del cliente;
- alertas recientes, intentos fallidos y resultado de verificaciones anteriores.

No se utilizaría únicamente la transacción aislada, porque una compra de Q2,000 puede ser normal para un cliente y anómala para otro. Por ello, el estado debe incorporar contexto histórico suficiente para aproximar la propiedad de Markov: la decisión futura debería depender principalmente del estado actual y no de información relevante que haya sido omitida [1].

b) Espacio de acciones $\mathcal{A}$. El agente podría seleccionar una de las siguientes acciones:

1. **Aprobar** la transacción sin pasos adicionales.
2. **Solicitar autenticación reforzada**, por ejemplo, código de un solo uso o confirmación biométrica.
3. **Retener temporalmente** la transacción para revisión automática o manual.
4. **Rechazar** la transacción y generar una alerta preventiva.

Estas acciones representan distintos niveles de intervención. Aprobar reduce fricción para el cliente, mientras que retener o rechazar disminuye el riesgo financiero, pero puede afectar negativamente la experiencia de usuarios legítimos.

c) Función de recompensa R . La recompensa debe equilibrar la reducción de fraude con la experiencia del cliente. Una propuesta inicial sería:

$$R_t = \begin{cases} +10, & \text{si se detiene correctamente una operación fraudulenta,} \\ +2, & \text{si se aprueba correctamente una operación legítima,} \\ -25, & \text{si se aprueba una operación fraudulenta,} \\ -8, & \text{si se rechaza una operación legítima,} \\ -1, & \text{si se solicita una verificación adicional innecesaria.} \end{cases}$$

La penalización por aprobar fraude es la mayor porque puede producir pérdida monetaria, costos operativos y daño reputacional. Sin embargo, también se castigan los falsos positivos, ya que bloquear clientes legítimos de manera frecuente puede provocar abandono, quejas y pérdida de confianza. En una implementación real, estas cantidades se ajustarían con datos históricos y podrían escalarse según el monto de la transacción. También convendría incorporar recompensas retrasadas relacionadas con reclamaciones, confirmaciones del cliente o recuperación de fondos.

d) Observabilidad del entorno. El entorno es **parcialmente observable**. Al momento de decidir, el sistema no conoce directamente si la intención de la persona es legítima, si las credenciales fueron robadas o si el titular realmente autorizó la operación. Solo observa señales indirectas y posiblemente incompletas.

Por esta razón, el problema puede modelarse como un proceso de decisión de Markov parcialmente observable (POMDP). El agente mantiene una estimación o creencia sobre la probabilidad de fraude a partir de la evidencia disponible, en lugar de observar el estado real de forma perfecta [2]. Esta característica explica por qué dos transacciones con datos similares pueden requerir decisiones diferentes según el historial y el nivel de incertidumbre.

1.2 Pregunta 2: Selección del factor de descuento γ

Pregunta:

Para el sistema elegido, argumente qué valor de γ sería más apropiado y por qué. Incluya al menos un ejemplo numérico que ilustre las consecuencias de elegir γ alto versus γ bajo para ese dominio específico.

Respuesta:

Para este sistema proponemos un valor de $\gamma = 0.95$. Es un valor alto porque una acción antifraude no debe evaluarse únicamente por su consecuencia inmediata. Solicitar autenticación adicional puede causar una pequeña molestia ahora, pero evitar posteriormente una pérdida financiera, una reclamación y el bloqueo completo de la cuenta. De la misma forma, aprobar rápidamente todas las operaciones puede generar satisfacción inmediata, pero aumentar pérdidas futuras.

El retorno descontado desde el instante $t = 0$ se define como:

$$G_0 = R_1 + \gamma R_2 + \gamma^2 R_3 + \dots$$

Supongamos que solicitar una verificación genera una recompensa inmediata de -2 por la fricción ocasionada. Tres pasos después, la verificación permite detener un fraude y produce una recompensa de $+20$. Entonces:

$$G_0 = -2 + \gamma^3(20).$$

Valor de γ	Cálculo	Retorno G_0
0.95	$-2 + (0.95)^3(20)$	15.15
0.50	$-2 + (0.50)^3(20)$	0.50

Cuadro 1: Efecto del factor de descuento en una acción preventiva.

Con $\gamma = 0.95$, el beneficio futuro conserva suficiente importancia y la verificación resulta claramente conveniente. Con $\gamma = 0.50$, la misma consecuencia futura queda fuertemente descontada y el agente podría preferir evitar la molestia inmediata, aunque eso aumente el riesgo posterior. Un γ demasiado cercano a cero produciría una estrategia miope; uno extremadamente cercano a uno podría hacer el aprendizaje más sensible a recompensas lejanas y aumentar la dificultad de asignar crédito a cada decisión. Por ello, 0.95 ofrece un equilibrio razonable entre consecuencias inmediatas y protección a mediano plazo.

1.3 Pregunta 3: Política determinista y política estocástica

Pregunta:

Describe en lenguaje natural una política determinista y una política estocástica para su sistema elegido. ¿En qué escenario preferiría una política estocástica sobre una determinista?

Respuesta:

Política determinista. Una política determinista selecciona siempre la misma acción para un estado determinado. Por ejemplo, el sistema podría calcular una puntuación de riesgo entre 0 y 1 y aplicar las siguientes reglas:

- si el riesgo es menor que 0.60, aprobar la operación;
- si está entre 0.60 y 0.85, solicitar autenticación reforzada;
- si es mayor o igual que 0.85, rechazar y generar una alerta.

En esta política, una transacción con riesgo 0.70 siempre produce la acción de autenticación reforzada. Su ventaja principal es que es predecible, auditable y sencilla de explicar ante clientes y equipos de cumplimiento.

Política estocástica. Una política estocástica asigna probabilidades a las acciones. Para una operación con riesgo intermedio y alta incertidumbre, por ejemplo, podría seleccionar:

$$\pi(a \mid s) = \begin{cases} 0.70, & \text{solicitar autenticación reforzada,} \\ 0.20, & \text{aprobar con monitoreo posterior,} \\ 0.10, & \text{enviar a revisión temporal.} \end{cases}$$

Preferiríamos una política estocástica cuando existen varios cursos de acción razonables y se necesita explorar cuál funciona mejor, especialmente durante pruebas controladas, simulación u optimización con datos históricos. También puede ser útil en estados ambiguos, donde una regla rígida produciría siempre el mismo tipo de error.

No obstante, la exploración debe estar limitada por reglas de seguridad. En operaciones con evidencia muy fuerte de fraude no sería conveniente actuar aleatoriamente. La política estocástica debería aplicarse únicamente en una zona de riesgo intermedio y bajo controles que limiten pérdidas y protejan al cliente. En producción, una estrategia práctica sería combinar una política aprendida con restricciones deterministas de cumplimiento y seguridad.

2 Task 2: Modificaciones al GridWorld

Se ejecutaron cinco episodios por configuración con la semilla 42 para obtener resultados reproducibles. Reiniciar la semilla antes de cada experimento permite comparar las configuraciones bajo la misma secuencia de acciones aleatorias. El retorno de cada episodio se calculó mediante la expresión recursiva vista en clase:

$$G_t = R_{t+1} + \gamma G_{t+1}.$$

2.1 Cambio del factor de descuento γ

Se modificó el factor de descuento a $\gamma = 0.5$ y $\gamma = 0.99$ para determinar cómo cambia el retorno promedio entre episodios.

```
GAMMA = 0.5
Retornos G0: [-2.0117, -2.0, -2.0, -2.0, -2.0007]
Promedio: -2.0025 | Minimo: -2.0117 | Maximo: -2.0000
Pasos: [9, 22, 50, 17, 13]
Finales: ['trampa (1, 1)', 'trampa (1, 1)', 'meta',
          'trampa (2, 3)', 'trampa (1, 1)']

GAMMA = 0.99
Retornos G0: [-12.3393, -23.0759, -32.7771, -19.1115, -15.7934]
Promedio: -20.6194 | Minimo: -32.7771 | Maximo: -12.3393
Pasos: [9, 22, 50, 17, 13]
Finales: ['trampa (1, 1)', 'trampa (1, 1)', 'meta',
          'trampa (2, 3)', 'trampa (1, 1)']
```

γ	Promedio	Mínimo	Máximo
0.50	-2.0025	-2.0117	-2.0000
0.99	-20.6194	-32.7771	-12.3393

Cuadro 2: Comparación de retornos para distintos valores de γ .

Observación. El retorno promedio disminuyó de -2.0025 con $\gamma = 0.5$ a -20.6194 con $\gamma = 0.99$, aunque se ejecutaron las mismas acciones gracias al uso de la misma semilla. Con $\gamma = 0.5$, las recompensas futuras se descuentan rápidamente y G_0 depende principalmente de las primeras transiciones; con $\gamma = 0.99$, las penalizaciones de trayectorias largas conservan casi todo su peso. Por ello, el episodio de 50 pasos obtuvo el retorno más negativo con $\gamma = 0.99$, aunque finalmente alcanzó la meta.

2.2 Nueva trampa en (0,3)

Se agregó el estado (0,3) al conjunto de trampas y se comparó la distribución de retornos con la configuración original.

```
TRAMPAS ORIGINALES
Retornos G0: [-10.0487, -14.8916, -17.5702, -13.3981, -11.8946]
Promedio: -13.5606 | Minimo: -17.5702 | Maximo: -10.0487
Pasos: [9, 22, 50, 17, 13]
Finales: ['trampa (1, 1)', 'trampa (1, 1)', 'meta',
```

```

      'trampa (2, 3)', 'trampa (1, 1)']

CON NUEVA TRAMPA (0, 3)
Retornos G0: [-10.0487, -14.8916, -17.5702, -13.3981, -7.1394]
Promedio: -12.6096 | Mínimo: -17.5702 | Máximo: -7.1394
Pasos: [9, 22, 50, 17, 4]
Finales: ['trampa (1, 1)', 'trampa (1, 1)', 'meta',
          'trampa (2, 3)', 'trampa (0, 3)']

```

Configuración	Promedio	Mínimo	Máximo
Trampas originales	-13.5606	-17.5702	-10.0487
Nueva trampa en (0,3)	-12.6096	-17.5702	-7.1394

Cuadro 3: Efecto de agregar una nueva trampa en la distribución de retornos.

Observación. Al agregar la trampa en (0,3), el retorno promedio aumentó de -13.5606 a -12.6096 y el retorno máximo pasó de -10.0487 a -7.1394 . La modificación afectó únicamente al quinto episodio, que terminó en la nueva trampa después de 4 pasos, mientras que los otros cuatro retornos permanecieron iguales. Aunque el resultado parece contradictorio, terminar rápidamente permitió acumular menos penalizaciones de -1 , lo cual indica que la recompensa de -5 quizá no penaliza suficientemente la caída en una trampa.

2.3 Recompensa por paso de -1 a -0.1

Se redujo la penalización de cada transición no terminal para analizar su efecto sobre el retorno y el comportamiento del agente.

```

RECOMPENSA POR PASO = -1.0
Retornos G0: [-10.0487, -14.8916, -17.5702, -13.3981, -11.8946]
Promedio: -13.5606 | Mínimo: -17.5702 | Máximo: -10.0487
Pasos: [9, 22, 50, 17, 13]
Finales: ['trampa (1, 1)', 'trampa (1, 1)', 'meta',
          'trampa (2, 3)', 'trampa (1, 1)']

RECOMPENSA POR PASO = -0.1
Retornos G0: [-3.9903, -3.0217, -1.0281, -3.3204, -3.6211]
Promedio: -2.9963 | Mínimo: -3.9903 | Máximo: -1.0281
Pasos: [9, 22, 50, 17, 13]
Finales: ['trampa (1, 1)', 'trampa (1, 1)', 'meta',
          'trampa (2, 3)', 'trampa (1, 1)']

```

Recompensa por paso	Promedio	Mínimo	Máximo
-1.0	-13.5606	-17.5702	-10.0487
-0.1	-2.9963	-3.9903	-1.0281

Cuadro 4: Efecto de la recompensa por paso sobre los retornos.

Observación. Al cambiar la recompensa por paso de -1 a -0.1 , el retorno promedio aumentó de -13.5606 a -2.9963 , porque las transiciones no terminales fueron diez veces

menos costosas. La cantidad de pasos y los estados terminales no cambiaron, ya que el agente sigue una política aleatoria fija y no utiliza las recompensas para actualizar su comportamiento. En un agente que sí aprendiera, esta modificación reduciría la presión por finalizar rápidamente y podría favorecer trayectorias más largas pero seguras, dependiendo de las recompensas terminales.

2.4 Conclusión

Los experimentos muestran que γ determina cuánto influyen las consecuencias futuras en G_0 , mientras que la ubicación de los estados terminales y la magnitud de las recompensas modifican la distribución de los retornos. En este caso, el comportamiento observable no cambia al modificar las recompensas porque el agente utiliza una política aleatoria sin aprendizaje.

Referencias

- [1] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- [2] Kaelbling, L. P., Littman, M. L., & Cassandra, A. R. (1998). Planning and acting in partially observable stochastic domains. *Artificial Intelligence*, 101(1–2), 99–134.
- [3] Puterman, M. L. (1994). *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley.